


20250811日报

今日工作内容

1. 添加上报点，添加电话告警；

a. 下面给出天机阁上报后的查询结果：



可以看出，Grafana中看到了各个上报的服务点。

b. 添加电话告警；

i. 学习通过GitOps设置告警，设置的PromQL如下：

```
1 - alert: "正式服服务存在debug日志级别"
2   expr: |
3     sum by (_name, server) (increase(trpc_counter_total[_name=~"Production
4     alert:.*",_type="counter",server="trpc_log_scanner",namespace=~"Production",ten
5     ant_id="sgameai"])[1m])) > 0
6   for: 1m
7   labels:
8     send_phone: true
9     severity: 通知
```

明天等MR到master后，再进行检验。

2. 调研torch serve；

a. 定义：TorchServe是Pytorch官方推出的生产级模型部署框架，专为高效、可扩展的模型推理服务设计；

b. TorchServe采用前后端分离架构：

i. 前端组件（Java实现）：

1. 管理HTTP/REST和gRPC请求的分发；
2. 动态分配任务到后端工作线程；
3. 批处理多个请求；
4. 提供推理（8080）、管理（8081）、指标（8082）三类端口；

- ii. 后端工作进程 (Python实现) :
 - 1. 模型加载 : 通过Model Loader加载模型文件及依赖 ;
 - 2. 推理执行 : 由工作进程池并行处理请求 ;
 - 3. 自定义处理 : 通过Handler脚本实现数据预处理、推理和后处理逻辑 ;
- iii. 模型存储 :
 - 1. 目录结构包含模型文件 (.pt/.pth) 、权重、元数据及预处理脚本 ;
 - 2. 支持本地文件系统或云存储 ;
- c. 核心工作流程 :
 - i. 模型归档 : 使用 torch-model-archiver 将模型、处理器 (Handler) 和依赖文件打包为 .mar 文件 ;
 - ii. 服务启动 : 如 torchserve --start --model-store model_store --models resnet=resnet.mar ;
 - iii. 客户端上游请求 ;
- 3. 初步修改了一下星币专区需求 , 需要添加次元部件投放、次元主题、次元主题投放的字段 ; 明天继续调试 ;

```

1  switch item.GetType() {
2      case "次元主题":
3          infoList := sheet.Get(
4              ctx, ctx.ClientVersion,
5              version_proxy.SheetScene_DimensionConfig_DimensionOutfit, ctx.ClientSvn,
6              ).GetDimensionConfigDimensionOutfit().GetItems()
7          infoMap := lo.SliceToMap(
8              infoList,
9              func(item *version_proxy.DimensionConfigDimensionOutfit_Item)
10             (int64, *version_proxy.DimensionConfigDimensionOutfit_Item) {
11                 return item.GetId(), item
12             },
13             )
14         quality = infoMap[item.GetId()].GetQuality()
15         resType =
16         keywords.RES_ITEM_TYPE_RES_ITEMTYPE_DIMENSION_OUTFIT
17     case "次元部件":
18         infoList := sheet.Get(
19             ctx, ctx.ClientVersion,
20             version_proxy.SheetScene_DimensionPart_DimensionPart, ctx.ClientSvn,
21             ).GetDimensionPartDimensionPart().GetItems()
22         infoMap := lo.SliceToMap(
23             infoList,
24             func(item *version_proxy.DimensionPartDimensionPart_Item)
25             (int64, *version_proxy.DimensionPartDimensionPart_Item) {
26                 return item.GetId(), item
27             },
28             )
29         quality = infoMap[item.GetId()].GetQuality()
30         resType =
31         keywords.RES_ITEM_TYPE_RES_ITEMTYPE_DIMENSION_UNIT
32     case "次元主题投放":
33         infoList := sheet.Get(

```

明日待办：

1. 推进trpc_log_scanner需求；
2. 推进"--story=126521650 【数据】星币转区接入新的规则排序-补充次元主题品质--工程"需求；